

Оглавление

1	Эволюция СУБД	2
1.1	Базы данных и файловые системы	2
1.2	Формирование современных СУБД	2
1.3	Развитие технологий баз данных	4
2	Понятие и архитектура СУБД	7
2.1	Понятие и функции СУБД	7
2.2	Физическая организация СУБД	9
2.2.1	Общие компоненты СУБД	9
2.2.2	Функциональная структура	10
2.2.3	Схема функционирования СУБД	11
2.3	Интерфейсы баз данных	11
3	Организация удаленного доступа к данным СУБД	13
3.1	Модели доступа к данным	13
3.2	Архитектуры доступа	14

1 ЭВОЛЮЦИЯ СУБД

1.1 Базы данных и файловые системы

Исторически прообразом систем управления базами данных (или систем управления данными) служили **файловые системы**. Файловые системы были первыми системами хранения данных, из которых выросли современные СУБД. У них много черт, которые присутствуют и развиваются в нынешних системах хранения. Рассмотрим схожие моменты и принципиальные отличия.

Исторические направления использования ВТ:

1. Применение для выполнения численных расчетов.
2. **Использование в автоматических или автоматизированных информационных системах. (позже первого)**

С точки зрения прикладной программы файл - это именованная область внешней памяти, в которую можно записывать и из которой можно считывать данные.

Файл – неструктурированный текст (структура определяется приложением). Особенность файловых систем – **без схемное** хранение данных. Без схемное хранение – основное отличие файловой системы от СУБД в ее современном понимании. Но файловые системы обладают многими чертами и зачатками функционала СУБД.

Тогда были сформированы функции системы хранения, такие как распределение внешней памяти, отображение имен файлов в соответствующие адреса во внешней памяти и обеспечение доступа к данным.

Физически файл на диске представляет собой последовательность байт, последовательность записей (постоянной или переменной длины) или запись также структурируется на поля, некоторые из них объявляются ключами записей (дескрипторное представление). Однако к содержимому файла разбиение записи отношения не имеет (то есть, схемы данных все еще нет).

Не смотря на то, что интерпретацию хранимой в файлах информации осуществляло непосредственно прикладное программное обеспечение, файловые системы отвечали за:

- управление внешней памятью,
- организацию физического хранения а виде последовательностей байт или последовательностей записей,
- использование буферов данных,
- структуризацию данных для ускорения поиска в виде деревьев каталогов различной структуры (без учета содержимого файла).

Более высокие требования информационных систем к хранению информации, такие как

- необходимость внутренней структуризации данных,
- обеспечение их согласованности,
- восстановления при сбоях и
- множественный доступ,

обусловили появление выделенного класса систем управления данными или систем управления базами данных – СУБД.

1.2 Формирование современных СУБД

Без схемный подход приведенный выше приводил к тому, что проблемы структуризации данных решались индивидуально в каждой информационной системе. В больших системах это приводило к существенным проблемам согласования информации и разработки кода. Поэтому следующим этапом развития стали программные библиотеки информационных систем.

1. Библиотеки ИС

Производились необходимые надстройки над файловыми системами (библиотеки программ), подобно тому, как это делается в компиляторах, редакторах и т.д.

Задачи:

1. Структуры данных
2. Целостность данных
3. Языки запросов
4. Транзакции, журнализация и многопользовательский режим



С развитием технологий появились новые требования ИС, которым перестали удовлетворять библиотеки:

- большие объемы данных (тысячи, миллионы и более строк)
- высокая скорость обработки
 - в ОП нельзя держать все данные (не входит)
 - на дисках медленный доступ
 - последовательный характер работы процессоров (даже в многопроцессорной системе)

Это привело к следующему этапу развития – СУБД встроенным в операционные системы.

2. СУБД в составе ИС



Для решения приведенных выше проблем используются:


- **многоступенчатость поиска;** *Многоступенчатость* проявляется в том, что прикладная программа работает не напрямую с большими базами данных, но только с так называемыми индексами или ключами, то есть малой частью объема информации, которая является указателем, где искать целевые данные.
- **препроцессорность поиска;** *Препроцессорность* поиска проявляется в том, что такая малая часть информации подготавливается в виде специальных индексных таблиц или файлов, в которых хранятся не сами данные, но только указатели на них.
- **структурирование данных.**

Минусы:

- Повторение функционала СУБД в разных ИС (или как встраивать готовую СУБД в ИС?)
- Связанность на конкретной СУБД метаданных

3. СУБД как выделенный компонент

Современные промышленные СУБД отвечают архитектуре – СУБД как выделенный компонент, обеспечивая общую структуризацию данных для большого числа прикладных программ и даже разных предметных областей (например, совместное ведение кадровой и проектной информации).



1.3 Развитие технологий баз данных

Обозначим следующие периоды развития систем управления данными:

1. *Формирование базовых технологий СУБД.*
2. *Распределенные и разделяемые хранилища данных.*
3. *Аналитические и объектные системы управления данными.*
4. *Интеграция информационных ресурсов в управлении данными. Специализированные СУБД.*
5. *Управление большими данными.*

I Исторически период до 80-х гг двадцатого века можно отнести к становлению направления по обработке данных в информационных технологиях. В этот период были проведены первые исследования, симпозиумы и представлены первые, ставшие широко известными, промышленные СУБД. С технологической точки зрения они относились к СУБД построенным на сетевой (IDS – Integrated Data Storage) и иерархической (IMS – Information Management System) моделях данных.

С семидесятых годов начинается эпоха реляционных баз данных и СУБД System R и Ingres. В это время происходит

- формирование понятия модели данных и
- математических основ моделирования информации,
- языков запросов,
- базового функционала СУБД.

II Со второй половины 70-х гг. и в течении 80-х происходит дальнейшее развитие проектов СУБД, заложенных на предыдущем этапе. В связи с изменениями требований информационных систем возникает необходимость в:

- распределенном доступе к данным и развитие клиент – серверной архитектуры в управлении данными.
- оперировать в деятельности различных подразделений и организаций одними и теми же наборами данных.

Разрабатываются

- распределенные версии System R* и Ingress. Тогда же появляется
- концепция расширяемой СУБД, функционал которой наращивается введением дополнительных модулей, индексов и инструментов.
- стандартизация языка SQL, как основного средства манипулирования данными,
- появляются новые типы индексов
- средства оптимизации запросов.

Основы наиболее известных СУБД – DB2, Informix, Sybase, Postgres, Oracle были заложены в тот период.

III С наступлением девяностых происходит, с одной стороны,

- персонализация СУБД. Они начинают широко применяться в частных целях.
- возникает необходимость приближения доминирующих реляционных серверов и объектно – ориентированной концепции построения приложений.

Этот процесс приводит к

- попыткам создания объектно-ориентированных баз данных (ODBMS)[28] и
- интеграции объектных расширений в большинство промышленных серверов,
- появляются объектные расширения языка SQL закрепленные в стандарте.
- Построение аналитических OLAP – систем на базе систем управления данными
- Широкое распространению трехзвенной архитектуры с использованием серверов приложений,
- появлению СУБД для мобильных устройств.

IV Начало двадцатого века характеризуется

- продолжением специализации СУБД.
- Требования крупных компаний обуславливают необходимость интеграции данных из различных источников и

- создание высокопроизводительных аналитических систем.
- Развиваются подходы эффективного хранения в СУБД сложных структур данных, таких как графы, XML, мультимедиа.

Этот период характеризуется созданием масштабных систем по управлению и обработке данных, начиная с поисковых гигантов google, amazon, facebook. Характерной чертой этого периода является уже произошедшее широкое проникновение СУБД в internet – технологии и системы распределенного удаленного доступа в самых различных коммерческих отраслях.

V На рубеже 2010-х возникает большое количество специальных задач по хранению и обработке данных, таких как хранение логов приложений, хранение данных текущих транзакций в памяти т.д. В результате на границе 2010-х годов возникает ряд новых систем управления базами данных, называемых «NoSQL» [29], в которых происходит

- отказ от традиционной структуризации данных с целью увеличения общей производительности.
- системы управления большими данными, объединяющие в себе при помощи программных интерфейсов, компонентов и вычислительных сред гетерогенные хранилища данных различной структуры и назначения


Таблица 1. Эволюция технологий и безопасности СУБД

Этап развития СУБД	Технологии управления данными	Новые источники угроз безопасности	Новые технологии защиты данных
Формирование базовых технологий СУБД.	Понятие модели данных Математические основы СУБД Языки запросов Управление внешней и оперативной памятью, синхронизация транзакций.	Статистический вывод над данными; Физическое воздействие на сервер данных.	Технологии физической защиты. Шифрование данных (при хранении на диске). Мандатное разграничение доступа (MAC).
Распределенные и разделяемые хранилища данных.	Распределенные транзакции; индексы и средства ускорения выполнения запросов.	Подмена пользователя и пользовательского запроса.	Фильтры запросов. Дискреционное разграничение доступа (DAC).
Аналитические и объектные системы управления данными.	Расширяемые, объектные и аналитические СУБД, ODBMS.	Перехват сообщений. Удаленный доступ к серверу СУБД. Логический и статистический вывод над данными.	Ролевое разграничение доступа (RBAC). Шифрование данных (при передаче). Защита и фильтрация входных данных.
Интеграция информационных ресурсов в управлении данными. Специализированные СУБД.	Физическая и виртуальная интеграция ресурсов, шлюзы СУБД, комплексы ПО на базе сервера СУБД.	НСД путем повышения привилегий, эксплуатация привилегий DBA.	Сквозное шифрование данных. Защищенный аудит и логгирование. Онтологический доступ (OBAC).
Управление большими данными.	Объединение множества распределенных специализированных СУБД и программной среды обработки данных.	Недоверенные узлы – обработчики данных и недоверенная внутренняя среда передачи данных.	Изоляция внутренней среды обработки данных. Унификация разграничения доступа к гетерогенным структурам данных (атрибутивный доступ ABAC). Распределенная авторизация, аутентификация и аудит.

Системы управления большими данными

С точки зрения эволюции, системы управления Большими данными являются закономерным развитием систем обработки и управления информацией. Рассматривая их развитие (рис.), можно отметить следующие закономерности:

1. Системы управления данными планомерно развивались в сторону универсальности и расширения производительности.
2. Каждый последующий класс систем включал в себя предыдущий, как адаптированный и интегрированный в новую архитектуру компонент.
3. В процессе эволюции системы управления данными последовательно проходят периоды разработки новых компонентов, решений и архитектур, которые существуют сначала как частные наборы решений, а потом интегрируются в единые комплексы, с повышением универсализации.



Таким образом, системы управления Большими данными представляют собой закономерное развитие распределенных систем управления базами данных. Под высокой нагрузкой по данным случае, понимается не вычислительная сложность задач и операций, а именно высокая нагруженность систем в связи с информационными характеристиками: объемом хранимых и поступающих в единицу времени данных, разнообразием обрабатываемой информации.

2 ПОНЯТИЕ И АРХИТЕКТУРА СУБД

2.1 Понятие и функции СУБД

База данных — представленная в объективной форме совокупность самостоятельных материалов (статей, расчётов, нормативных актов, судебных решений и иных подобных материалов), систематизированных таким образом, чтобы эти материалы могли быть найдены и обработаны с помощью электронной вычислительной машины (ЭВМ)

Система баз данных — это, компьютеризированная система хранения однотипных записей.

Система управления базами данных, СУБД (англ. Database Management System, DBMS) — совокупность программных и лингвистических средств общего или специального назначения, обеспечивающих управление созданием и использованием баз данных (*ГОСТ Р ИСО МЭК ТО 10032-2007: Эталонная модель управления данными (идентичен ISO/IEC TR 10032:2003 Information technology — Reference model of data management)*)

СУБД (в практическом понимании) — комплекс программ, позволяющих создать базу данных (БД) и манипулировать данными (вставлять, обновлять, удалять и выбирать). Система обеспечивает безопасность, надёжность хранения и целостность данных, а также предоставляет средства для администрирования БД.

Система управления базой данных (СУБД) представляет собой программное обеспечение, которое управляет всем доступом к базе данных. Концептуально это происходит следующим образом:

1. Пользователь выдает запрос на доступ к данным, применяя определенный подъязык данных (обычно это язык SQL).
2. СУБД перехватывает этот запрос и анализирует его.
3. СУБД просматривает внешнюю схему (ее объектную версию) для этого пользователя, соответствующее отображение "внешний—концептуальный", концептуальную схему, отображение "концептуальный—внутренний" и определения структур хранения.
4. СУБД выполняет необходимые операции в хранимой базе данных.

Функции СУБД

1. Непосредственное управление данными во внешней памяти

Эта функция включает обеспечение необходимых структур внешней памяти как для хранения данных, непосредственно входящих в БД, так и для служебных целей, например, для убыстрения доступа к данным в некоторых случаях (обычно для этого используются индексы).

2. Управление буферами оперативной памяти

Помимо того, что современные СУБД сами управляют выделенными им буферами оперативной памяти, существует отдельное направление СУБД, которое ориентировано на постоянное присутствие в оперативной памяти всей БД. *Это направление основывается на предположении, что в будущем объем оперативной памяти компьютеров достаточно велик, что позволит не беспокоиться о буферизации.* Сегодня это ряд транзакционных СУБД (например, MemcashDB)

3. Управление транзакциями

Транзакция - это последовательность операций над БД, рассматриваемых СУБД как единое целое. Либо транзакция успешно выполняется, и СУБД фиксирует (COMMIT) изменения БД, произведенные этой транзакцией, во внешней памяти, либо ни одно из этих изменений никак не отражается на состоянии БД.

Примером транзакции может служить финансовая операция перевода денег со счета А на счет Б. При этом также важно свойство **идемпотентности**: возможности повторить операцию без изменения ее результата.

транзакции - единицы активности пользователя по отношению к БД (*II семестр: коммерческие и фактические транзакции*).

С управлением транзакциями в многопользовательской СУБД связаны важные понятия *сериализации транзакций и сериального плана выполнения смеси транзакций*.

Существует несколько базовых алгоритмов сериализации транзакций.

4. Журнализация

Одним из основных требований к СУБД является надежность хранения данных во внешней памяти. Под надежностью хранения понимается то, что СУБД должна быть в состоянии восстановить

последнее согласованное состояние БД после любого аппаратного или программного сбоя.

Обычно рассматриваются **два возможных вида аппаратных сбоев**:

1. так называемые *мягкие сбои*, которые можно трактовать как *внезапную остановку работы компьютера (например, аварийное выключение питания)*, и
2. *жесткие сбои*, характеризующиеся *потерей информации на носителях внешней памяти*.

Журнал - это особая часть БД, недоступная пользователям СУБД и поддерживаемая с особой тщательностью (иногда поддерживаются две копии журнала, располагаемые на разных физических дисках), в которую поступают записи обо всех изменениях основной части БД.

В разных СУБД изменения БД журналируются на разных уровнях:

- иногда запись в журнале соответствует некоторой логической операции изменения БД (например, операции удаления строки из таблицы реляционной БД),
- иногда - минимальной внутренней операции модификации страницы внешней памяти;
- в некоторых системах одновременно используются оба подхода.

5. Поддержка языков БД (SQL)

Отличия от системы управления файлами:

■ Система управления файлами не имеет никаких сведений о внутренней структуре хранимых записей и, следовательно, не способна обрабатывать запросы, требующие знания этой структуры.

■ Как правило, подобные системы предоставляют слабую поддержку ограничений защиты и поддержки целостности данных или же вообще ее не предоставляют.

■ Обычно такие системы предоставляют недостаточную поддержку управления восстановлением данных и параллельным доступом к ним или же не предоставляют ее вовсе.

■ На уровне диспетчера файлов не существует концепции настоящего **словаря данных**¹.

■ Вообще говоря, эти системы обеспечивают **независимость от данных** гораздо хуже по сравнению с СУБД.

■ Как правило, отдельные файлы не являются "интегрированными" или "разделяемыми" в том смысле, который вкладывается в эти понятия применительно к базам данных. (Обычно они являются собственными файлами пользователя или приложения.)

¹ Сам словарь данных вполне можно считать самостоятельной базой данных (но не пользовательской, а системной). Словарь содержит "данные о данных" (иногда называемые метаданными или дескрипторами), т.е. в нем находятся определения других объектов системы, а не просто обычные данные

2.2 Физическая организация СУБД

2.2.1 Общие компоненты СУБД

Логически в современной реляционной СУБД можно выделить наиболее внутреннюю часть –

1. **ядро СУБД (часто его называют Data Base Engine)**, Ядро СУБД отвечает за управление данными во внешней памяти, управление буферами оперативной памяти, управление транзакциями и журнализацию

- менеджер данных,
- менеджер буферов,
- менеджер транзакций и
- менеджер журнала

Ядро СУБД является основной резидентной частью СУБД.

2. **компилятор языка БД (обычно SQL)**, компиляция операторов языка БД в некоторую выполняемую программу
языки этих систем (а это, как правило, SQL) являются непроцедурными, т.е. в операторе такого языка специфицируется некоторое действие над БД, но эта спецификация не является процедурой, а лишь описывает в некоторой форме условия совершения желаемого действия

Поэтому компилятор должен решить, каким образом выполнять оператор языка прежде, чем произвести программу.

Результатом компиляции является выполняемая программа, представляемая в некоторых системах в машинных кодах, но более часто **в выполняемом внутреннем машинно-независимом коде**.

3. **подсистему поддержки времени выполнения**, В последнем случае реальное выполнение оператора производится с привлечением подсистемы поддержки времени выполнения, представляющей собой, по сути дела, интерпретатор этого внутреннего языка.
4. **набор утилит**. загрузка и выгрузка БД, сбор статистики, глобальная проверка целостности БД и т.д

Утилиты программируются с использованием интерфейса ядра СУБД, а иногда даже с проникновением внутрь ядра.

2.2.2 Функциональная структура



Основные компоненты БД (Core Components):

- **Диспетчер процессов.** Во многих БД имеется пул процессов/поток, которыми нужно управлять. Причём в погоне за производительностью некоторые БД используют свои собственные потоки, а не предоставляемые ОС.
- **Диспетчер сети.** Пропускная способность сети имеет большое значение, особенно для распределённых БД.
- **Диспетчер файловой системы.** Первым «бутылочным горлышком» любой БД является производительность дисковой подсистемы. Поэтому очень важно иметь диспетчер, который идеально работает с файловой системой ОС или даже заменяет её.
- **Диспетчер памяти.** Чтобы не упереться в невысокую производительность дисковой подсистемы, нужно иметь много оперативной памяти. А значит, нужно эффективно ею управлять, что и делает данный диспетчер. Особенно когда у вас много одновременных запросов, использующих память.
- **Диспетчер безопасности.** Управляет аутентификацией и авторизацией пользователей.
- **Диспетчер клиентов.** Управляет клиентскими соединениями.

Инструменты (Tools):

- **Диспетчер резервного копирования.** Назначение очевидно.
- **Диспетчер восстановления.** Используется для восстановления когерентного состояния БД после сбоя.
- **Диспетчер мониторинга.** Занимается протоколированием всех активностей внутри БД и используется для наблюдения за её состоянием.
- **Диспетчер общего управления.** Хранит метаданные (вроде наименований и структуры таблиц) и используется для управления базами, схемами, табличными пространствами и т.д.


Диспетчер запросов (Query Manager):

- **Парсер запросов.** Проверяет их валидность.
- **Рерайтер запросов.** Осуществляет предварительную оптимизацию.
- **Оптимизатор запросов.**
- **Исполнитель запросов.** Компилирует и исполняет.

Диспетчер данных (Data Manager):

- **Диспетчер транзакций.** Занимается их обработкой.
- **Диспетчер кэша.** Используется для отправки данных перед использованием и перед записью на диск.
- **Диспетчер доступа к данным.** Управляет доступом к данным в дисковой подсистеме.

2.2.3 Схема функционирования СУБД



2.3 Интерфейсы баз данных

Все СУБД имеют программные интерфейсы, которые позволяют подключаться к ним из сторонних приложений. Эти интерфейсы могут иметь вид программных библиотек различного уровня сложности и/или абстракции, а могут представлять собой драйверы для распространенных систем

взаимодействия с СУБД, как например JDBC (Java Database Connectivity) или ODBC (Open Database Connectivity).

Все интерфейсы должны реализовывать следующие функции.

Подключение к СУБД : Подключение к серверу СУБД подразумевает, как правило, указание пользователя, подключающегося к базе данных, пароля или другого способа аутентификации, и, собственно, базы данных, с которой планируется производить работу

Выполнение команд на языке запросов (SQL): В подавляющем большинстве случаев, после успешного подключения к СУБД, программный интерфейс позволяет выполнять SQL-команды непосредственно.

Получение данных от СУБД : Поскольку любой SQL-запрос возвращает множество кортежей, часто – особенно в языках со статической типизацией – требуются специальные средства для получения результатов запросов. Обычно это функции, позволяющие получать и итерировать полученные записи, а так же получать и преобразовывать типы значений столбцов конкретной записи.


Могут также использоваться промежуточные программные средства, обеспечивающие отображение программных данных и данных в СУБД. Пример – объектно-реляционные отображения или ORM – системы.

3 ОРГАНИЗАЦИЯ УДАЛЕННОГО ДОСТУПА К ДАННЫМ СУБД


3.1 Модели доступа к данным

1. Модель файлового сервера (File Server - FS)


Запросы к файловой системе




2. Модель доступа к удаленным данным (Remote Data Access – RDA)



3. Модель сервера базы данных (DataBase Server - DBS);




4. Модель сервера приложений (Application Server - AS).




3.2 Архитектуры доступа


Централизованная архитектура (а) и архитектура "один к одному" (б).




Размещение клиента и сервера на отдельных машинах



Много потоковая архитектура



Архитектура с виртуальным сервером



Многопоточковая мультисерверная архитектура.
(При этом каждый из серверов должен быть многопоточковым.)

